

Akademia Górniczo-Hutnicza im. Stanisława Staszica w Krakowie WYDZIAŁ ELEKTROTECHNIKI, AUTOMATYKI, INFORMATYKI I INŻYNIERII BIOMEDYCZNEJ

KATEDRA INFORMATYKI STOSOWANEJ

Praca dyplomowa inżynierska

Implementacja maszyny wirtualnej dla funkcyjnych języków programowania wspierających przetwarzanie współbieżne.

Implementation of a virtual machine for functional programming languages with support for concurrent computing.

Autor: Kajetan Rzepecki Kierunek studiów: Informatyka

Opiekun pracy: dr inż. Piotr Matyasik

Oświadczam, świadomy odpowiedzialności karnej za poświadczenie nieprawdy, że niniejszą pracę dyplomową wykonałem osobiście i samodzielnie i nie korzystałem ze źródeł innych niż wymienione w pracy.

Serdecznie dziękuję Lucynie za cierpliwość i wsparcie podczas tworzenia pracy.

Spis treści

1.	Wst	ęp	7
	1.1.	Motywacja pracy	8
	1.2.	Zawartość pracy	Ć
2.	Arc	hitektura ThesisVM	11
	2.1.	Reprezentacja pośrednia programów	12
	2.2.	Kompilacja kodu bajtowego	14
	2.3.	Interpretacja kodu bajtowego	16
	2.4.	Zarządzanie pamięcią	17
	2.5.	Przetwarzanie współbieżne	19
3.	Inte	rpreter kodu bajtowego	21
	3.1.	Modyfikacje i implementacja modelu TIM	22
	3.2.	Implementacja obiektów prostych	25
	3.3.	Implementacja obiektów złożonych	26
	3.4.	Implementacja i obsługa kodu bajtowego	28
	3.5.	Implementacja operacji prymitywnych	29
4.	Mod	del zarządzania pamięcią	31
	4.1.	Architektura współdzielonej sterty	31
	4.2.	Implementacja alokatora obiektów	32
	4.3.	Kolekcja obiektów nieosiągalnych	34
	4.4.	Kolekcja obiektów cyklicznych	36
5.	Mod	del przetwarzania współbieżnego	37
	5.1.	Implementacja symetrycznego multiprocessingu	37
	5.2.	Harmonogramowanie procesów	38
	5.3.	Implementacja Modelu Aktorowego	38
	5.4.	Implementacja przesyłania wiadomości	36
6.	Pod	sumowanie	41
	6.1	Interpreter kodu bajtowego	11

6 SPIS TREŚCI

	6.2.	Kolektor obiektów nieosiągalnych	41
	6.3.	Przetwarzanie współbieżne	41
	6.4.	Kierunki przyszłego rozwoju	41
Bi	bliog	rafia	43
Α.	Przy	kładowe programy	47
	A.1.	Interfejs i użytkowanie Thesis VM $\ \ldots \ \ldots \ \ldots \ \ldots \ \ldots$	47
	A.2.	"Hello world!"	47
	A.3.	Funkcje i operacje prymitywne	47
	A.4.	Factorial	47
	A.5.	Fibonacci	47
	A.6.	Współbieżne "Hello world!"	47
	A.7.	Współbieżne obliczanie silni	47
В.	Spis	y wbudowanych operatorów i funkcji	49
\mathbf{C}	Snis	v rysunków i fragmentów kodu	53

1. Wstęp

Tematem pracy jest implementacja maszyny wirtualnej dla funkcyjnych języków programowania wspierających przetwarzanie współbieżne.

Maszyna wirtualna jest warstwą abstrakcji leżącą pomiędzy programem a rzeczywistym sprzętem, która pozwala uniezależnić ów program od rozbieżności w działaniu różnych architektur komputerów. Wystarczy zaimplementować maszynę wirtualną dla danej architektury rzeczywistego sprzętu by umożliwić uruchamianie na niej wszystkich kompatybilnych z programów. Rysunek 1.1 prezentuje uproszczony schemat takiego rozwiązania - programy docelowe zostają skompilowane do *kodu bajtowego* akceptowanego przez maszynę wirtualną a dopiero ów bajtkod jest przez nią uruchamiany.



Rysunek 1.1: Schemat interakcji z Maszyną Wirtualną.

Przetwarzanie współbieżne opiera się o współistnienie wielu procesów, które konkurują o dostęp do współdzielonych zasobów. W kontekście pracy, przetwarzanie współbieżne jest rozumiane jako asynchroniczne przekazywanie wiadomości pomiędzy działającymi, autonomicznymi procesami, czyli jako Model Aktorowy [1, 2].

Celem pracy jest stworzenie interpretera kodu bajtowego zdolnego uruchamiać kod skompilowanych programów, kolektora obiektów nieosiągalnych umożliwiającego automatyczne zarządzanie pamięcią oraz architektury symetrycznego multiprocesora (SMP) zapewniającego rzeczywistą współbieżność uruchamianych programów w oparciu o Model Aktorowy. Językiem implementacji projektu jest język D (w wersji 2.0 opisanej w [3]), stosunkowo nowoczesny, kompilowany do kodu maszynowego następca języka C++.

1.1. Motywacja pracy

Motywacją powstania pracy są problemy napotkane podczas użytkowania języka Erlang [4], dotyczące wydajności przesyłania wiadomości średniego rozmiaru w obecnej, standardowej jego implementacji. Problemy owe zilustrowano na listingu 1.

Zaprezentowany fragment kodu odczytuje plik w formacie JSON, który następnie jest dekodowany do wewnętrznej reprezentacji posiadającej skomplikowaną strukturę, by ostatecznie został on wysłany do dużej liczby współbieżnie działających procesów celem dalszego przetwarzania (linia 8). Rozwiązanie takie powoduje znaczący spadek wydajności.

```
start() ->
      2
      transmogrify(Data).
3
4
   transmogrify(Data) ->
5
      Pids = framework:spawn_bajilion_procs(fun do_stuff/1),
6
      JSON = json:decode(Data),
                                     %% {[Dane ...]}
7
      framework:map reduce(Pids, JSON). %% !#63^@
9
   do stuff(JSON) ->
10
      %% Operacje na danych.
11
      result.
12
```

Listing 1: Fragment kodu prezentujący problem występujący w języku Erlang.

Język Erlang wykorzystuje skomplikowaną architekturę pamięci, która w różny sposób traktuje obiekty różnego typu. Większość obiektów, w szczególności skomplikowana strukturalnie reprezentacja danych w formacie JSON, przechowywana jest w prywatnych stertach każdego procesu i musi być kopiowana podczas przesyłania jej w wiadomościach pomiędzy nimi. Reguła ta nie dotyczy danych binarnych, w szczególności danych odczytanych z pliku, ponieważ te korzystają z innych algorytmów nie wymagających kopiowania kosztem większego zużycia pamięci.

W związku z tym, aby zaradzić problemowi opisanemu powyżej, wystarczy przenieść operację dekodowania danych odczytanych z pliku bezpośrednio do procesów na nich operujących (listing 2). W nowej wersji procesy przesyłają jedynie dane binarne, które nie wymagają kopiowania pamięci, a narzut wydajności spowodowany wielokrotnym ich dekodowaniem jest niższy niż ten spowodowany nadmiernym kopiowianiem. W efekcie, kod działa wydajniej, kosztem logiki przepływu danych i organizacji modułów.

Celem pracy jest uniknięcie problemu nadmiernego kopiowania pamięci przez wybranie odpowiedniego modelu pamięci i implementację algorytmów kolekcji obiektow nieosiągal-

Listing 2: Suboptymalne rozwiązanie problemu w języku Erlang.

nych, które umożliwiają przesyłanie wiadomości pomiędzy procesami bez konieczności kopiowania ich zawartości.

1.2. Zawartość pracy

W skład pracy wchodzi implementacja interpretera kodu bajtowego, kolektora obiektów nieosiągalnych oraz symetrycznego multiprocesora (SMP).

Sekcja 1 opisuje cele, motywację, zakres oraz zawartość pracy.

Sekcja 2 przybliża architekturę maszyny wirtualnej ThesisVM zaimplementowanej w ramach pracy, zaczynając od reprezentacji pośredniej programów (TVMIR) i jej kompilacji do kodu bajtowego, przez interpretację kodu bajtowego i zarządzanie pamięcią do projektu przetwarzania współbieżnego.

Sekcja 3 szczegółowo opisuje implementację interpretera kodu bajtowego maszyny wirtualnej ThesisVM. Zaprezentowane zostają reprezentacje różnych obiektów, na których operuje maszyna, implementacja wpudowanych operatorów i funkcji prymitywnych oraz reprezentacja i generowanie kodu bajtowego akceptowanego przez interpreter.

Sekcja 4 szczegółowo prezentuje implementację wybranego modelu pamięci, alokatora nowych obiektów oraz kolektora obiektów nieosiągalnych.

Sekcja 5 szczegółowo opisuje implementację asynchronicznego przekazywania wiadomości i symetrycznego multiprocesora w maszynie ThesisVM. Zaprezentowana zostaje implementacja Modelu Aktorowego i harmonogramowania procesów.

Sekcja 6 zawiera podsumowanie pracy oraz zarys możliwych kierunków dalszego rozwoju projektu.

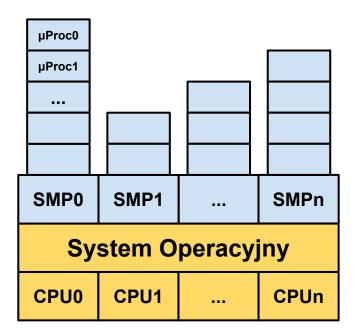
Dodatki A, B i C zawierają odpowiednio wskazówki użytkowania ThesisVM i przykładowe programy gotowe do uruchomienia na maszynie wirtualnej, spis wbudowanych operatorów i funkcji prymitywnych oraz spisy rysunków, tablic i fragmentów kodu znajdujących się w tekście pracy.

2. Architektura ThesisVM

Ninejsza sekcja opisuje architekturę maszyny wirtualnej ThesisVM powstałej na potrzeby pracy oraz języka przez nią akceptowanego.

Rysunek 2.1 zawiera schematyczną reprezentację maszyny wirtualnej ThesisVM uwzględniającą architekturę procesora sprzętu, na którym działa system operacyjny oraz sama maszyna wirtualna. Na schemacie widać poszczególne podsystemy ThesisVM, takie jak autonomiczne procesy (zwane dalej *mikroprocesami*, µProcN), czy symetryczne multiprocesory (zwane dalej SMPn).

Mikroprocesy są przypisane do symetrycznych multiprocesorów w stosunku wiele-dojednego, to znaczy każdy mikroproces jest przypisany do dokładnie jednego symetrycznego multiprocesora, który natomiast może zarządzać zbiorem wielu mikroprocesów.



Rysunek 2.1: Architektura maszyny wirtualnej ThesisVM.

Każdy symetryczny multiprocesor działa w osobnym wątku procesora sprzętowego, zapewniając rzeczywistą współbieżność. Wszystkie SMPn są takie same i wykonują ta-

kie same zadania, czyli harmonogramowanie i wywłaszczanie mikroprocesów, a różni je jedynie stan, w którym się znajdują oraz zbiór procesów, którymi zarządzają. Na schemacie widnieje mapowanie jeden-do-jednego pomiędzy rdzeniami procesora (CPUn) a poszczególnymi SMPn, nie jest to jednak wymóg konieczny i zależy od konfiguracji maszyny wirtualnej. Konfigurowalna ilość równocześnie działających SMP pomaga osiągnąć lepszą skalowalność maszyny wirtualnej i może być zmieniana dynamicznie wedle potrzeb.

Pozostając w zgodzie ze schematem przedstawionym na rysunku 1.1, interakcja z maszyną ThesisVM przebiega w analogiczny sposób. Kod programów w reprezentacji pośredniej (TVMIR) jest kompilowany do kodu bajtowego akceptowanego przez maszynę wirtualną, która następnie go ładuje i wykonuje umożliwiając zrównoleglenie obliczeń poprzez tworzenie nowych procesów i przesyłanie pomiędzy nimi wiadomości.

2.1. Reprezentacja pośrednia programów

ThesisVM wykorzystuje prostą reprezentację pośrednią programów w postaci TVMIR - języka lisp'owego z rodziny Scheme [5], który jest dostatecznie ekspresywny, by można w nim było zapisać nietrywialne algorytmy, a jednocześnie na tyle prosty, by ułatwić jego późniejszą kompilację do kodu bajtowego akceptowanego przez maszynę wirtualną.

Języki pośrednie reprezentacji programów są często stosowane w implementacjach wielu maszyn wirtualnych, takich jak ParrotVM, czy CoreVM [6], a także w implementacjach kompilatorów kodu maszynowego wielu języków programowania (na przykład GCC, LLVM). Reprezentacje pośrednie mają wiele zalet, począwszy od ułatwienia wsparcia dla szerszej gamy języków wysokiego poziomu, na możliwości tworzenia wygodnych założeń dodatkowych kończąc.

Na listingu 3 spisana w formacie BNF została gramatyka języka reprezentacji pośredniej wykorzystanego w maszynie wirtualnej ThesisVM. Gramatyka ta jest nieskomplikowana i w dużej mierze przypomina gramatiki różnych dialektów języka Lisp.

Języki z rodziny Lisp są bardzo wygodnym medium dla pośredniej reprezentacji programów ponieważ przedstawiają one drzewo syntaktyczne analizowanego kodu programu i nie wymagają skomplikowanego algorytmu parsowania. Dodatkowo, homoikoniczność tych języków może pomóc w tworzeniu narzędzi służących do przetwarzania kodu rozpatrywanego języka (w szczególności kompilatorów) bezpośrednio w rozpatrywanym języku. Temat ten został dogłębnie zbadany w [5]. Dodatek A zawiera przykłady kodu w języku pośredniej reprezentacji programów TVMIR.

Język reprezentacji pośredniej przedstawiony w pracy wymaga stworzenia kilku założeń dodatkowych dotyczących transformacji kodu. Najważniejszym z nich jest konieczność przeprowadzenia operacji lambda-unoszenia (ang. lambda lifting), opisanej bardzo dokładnie w [6], której efekt zaprezentowano na listingu 4.

```
program>
                     ::= <definitions>
1
   <definitions>
                     ::= <definition> <definition> | ''
                     ::= '(' 'define' '(' <symbol> <arguments> ')'
   <definition>
3
                                       <expression> ')'
4
                     ::= <symbol> <arguments> | ''
   <arguments>
5
   <expression>
                     ::= <value> | <application> | <primop>
6
                       | <conditional> | <quote> | <spawn>
                     ::= <list> | <symbol> | <number>
   <value>
8
   <application>
                     ::= '(' <expression> <expressions> ')'
9
                     ::= <exrpession> <exrpessions> | ''
   <expressions>
10
                     ::= '(' 'if' <expression>
   <conditional>
11
                                  <expression>
12
                                  <expression> ')'
                     ::= ''' <expression> | '(' 'quote' <epression> ')'
   <quote>
14
                     ::= '(' 'spawn' <symbol> <expression> ')'
   <spawn>
15
                     ::= '(' 'primop' <symbol> <expressions> ')'
   primop>
16
                     ::= '(' <expressions> ')'
   t>
17
                     ::= teral-string> | <atom>
   <symbol>
18
   teral-string> ::= '"' "Dowolny literał znakowy." '"'
19
                     ::= "Dowolny literał znakowy bez znaków białych."
   <atom>
20
                     ::= "Dowolny literal liczbowy."
   <number>
21
```

Listing 3: Gramatyka języka TVMIR.

Lambda-unoszenie polega na transformacji ciał funkcji w taki sposób, by tworzone w nich funkcje anonimowe zostały przeniesione na poziom główny zasięgu nazw (ang. top-level scope) dzięki czemu do ich implementacji wystarczy jedynie częściowa aplikacja funkcji. Na drugiej części listingu 4 funkcja make-adder zwracająca anonimową funkcję została transformowana na dwie funkcje, z których make-adder pozostaje funkcją unarną, która korzysta z częściowej aplikacji funkcji binarnej __make-adder_lambda0 wykonującej operację dodawania.

Pełna i poprawna implementacja operacji lambda-unoszenia jest skomplikowana, toteż nie została zawarta w dołączonym do projektu kompilatorze kodu bajtowego i musi zostać wykonana ręcznie.

Język pośredniej reprezentacji programów zastosowany w maszynie wirtualnej ThesisVM jest bardzo podobny do języka Core Lang wykorzystywanego w [6], jednak nie wspiera on niektórych jego konstrukcji, takich jak let(rec), czy definicje dowolnych obiektów złożonych. Z drugiej strony wspiera on konstrukcje związane z Modelem Akto-

Listing 4: Fragmenty kodu prezentujące operację lambda-unoszenia.

rowym (receive, send oraz spawn) oraz jest w stanie emulować brakujące konstrukcje odpowiednio przez wykorzystanie transformacji kodu połączonej z lambda-unoszeniem (listing 5) oraz "tagowania" list (przechowywania informacji o typie obiektu w pierwszym elemencie listy enkodującej ten obiekt).

```
;; Przed transformacją:
                                            ;; Po lambda-unoszeniu:
    (define (function x)
                                            (define (__function_lambda0 value)
2
      (let ((value (* 2 x)))
                                              (* value value))
                                        3
3
        (* value value)))
4
                                        4
                                           (define (function x)
5
                                        5
    ;; Po transformacji:
                                              ( function lambda0 (* 2 x)))
6
                                        6
    (define (function x)
      ((lambda (value)
         (* value value))
       (*2x))
10
```

Listing 5: Ograniczona implementacja konstrukcji let.

Kolejnym podobnym językiem reprezentacji pośredniej jest Core Erlang [7] wykorzystywany w standardowej implementacji języka Erlang. TVMIR jest bardzo okrojoną wersją języka Core Erlang, pozbawioną elementów dopasowywania wzorców, która jednak wspiera pozostałe ważne jego elementy, takie jak konstrukcje odpowiedzialne za tworzenie procesów oraz przesyłanie i odbieranie wiadomości. Istnieje możliwość rozszerzenia funkcjonalności TVMIR celem wsparcia pełnej specyfikacji Core Erlang [8], jednak jest to poza zakresem pracy. Więcej informacji o przyszłych kierunkach rozwoju projektu zostało zawarte w sekcji 6.4.

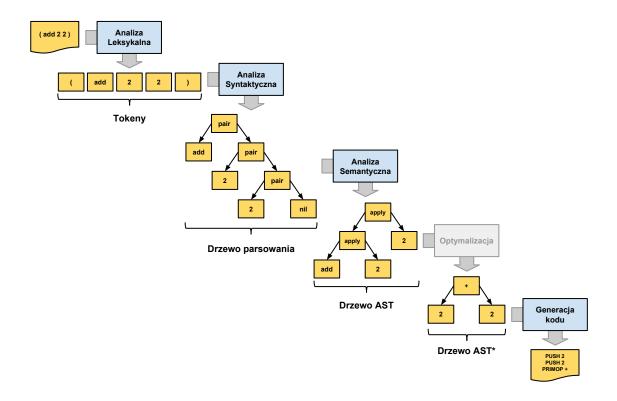
2.2. Kompilacja kodu bajtowego

Język pośredniej reprezentacji programów jest wygodnym medium do zapisu algorytmów, jednak wymaga on uprzedniego skompilowania do kodu bajtowego, który jest

akceptowany przez maszynę wirtualną ThesisVM.

Ponieważ kompilacja kodu nie jest *stricte* tematem pracy, mniej ważne szczegóły implementacji zostały pominięte, a niniejsza sekcja zarysowuje poszczególne fazy kompilacji kodu bajtowego ThesisVM.

Rysunek 2.2 zawiera schemat działania kompilatora kodu bajtowego ThesisVM wraz z przykładami pośrednich reprezentacji kompilowanego kodu w poszczególnych fazach kompilacji.



Rysunek 2.2: Schemat potokowega działania kompilatora kodu bajtowego ThesisVM wraz ze przykładami reprezentacji danych poszczególnych faz kompilacji.

Kompilator został zaimplementowany w sposób *potokowy*, to znaczy poszczególne fazy są logicznie odseparowane od siebie i wykonywane jedna po drugiej. Dzięki zastosowaniu leniwych konstrukcji języka D [3] wszystkie te fazy odbywają się *jednocześnie* i *na rządanie* a w przypadku wykrycia błędu w danej fazie poprzednie fazy natychmiastowo się kończą, bez konieczności przetworzenia całego zestawu danych, które otrzymały na wejściu.

Pierwszą fazą jest faza analizy leksykalnej, której zadaniem jest przetworzenie strumienia znaków kodu źródłowego programu w pośredniej reprezentacji TVMIR do strumienia tokenów, czyli elementarnych ciągów znaków będących leksemami języka. Faza ta przeprowadza także walidację składni na poziomie tokenów oraz filtrację niepotrzebnych tokenów (takich jak znaki białe, które nie mają znaczenia w TVMIR).

Drugą fazą jest faza analizy syntaktycznej, której zadaniem jest przetworzenie powstającego leniwie strumienia tokenów na wstępne drzewo parsowania składające się z prymitywnych konstrukcji języka TVMIR, takich jak listy, symbole i liczby. Faza ta waliduje składnię na poziomie zaawansowanych konstrukcji języka, które dzięki jego homoikoniczności zbudowane są z prymitywniejszych jego konstrukcji.

Trzecią fazą jest faza analizy semantycznej, której zadaniem jest przetworzenie wstępnego drzewa parsowania na bardziej abstrakcyjne drzewo składniowe (ang. Abstract Syntax Tree, AST) składające się semantycznie znaczących węzłów, takich jak aplikacja funkcji, wywołania operatorów wbudowanych, czy odwołania do zmiennych. Faza ta waliduje kod na poziomie semantycznym, sprawdzając poprawność wykorzystania różnych konstrukcji jezyka TVMIR.

Czwartą fazą jest faza optymalizacji, której zadaniem jest transformacja drzewa składniowego powstałego w poprzedniej fazie do jego ekwiwalentu działającego szybciej po skompilowaniu. Faza ta obecnie nie wykonuje żadnych interesujących transformacji, jednak istnieje możliwość rozszerzenia jej funkcjonalności w przyszłości (opisane krótko w sekcji 6.4).

Ostatnią, piątą fazą kompilacji jest faza generacji kodu bajtowego akceptowanego przez ThesisVM. Zadaniem tej fazy jest przetworzenie drzewa składniowego do strumienia kodu bajtowego za pomocą reguł kompilacji zgodnych z wybranym modelem maszyny wirtualnej.

2.3. Interpretacja kodu bajtowego

Istnieje wiele różnych modeli maszyn wirtualnych cechujących się różnymi architekturami interpreterów kodu bajtowego, czy nawet stopniem abstrakcyjności (tak zwane maszyny abstrakcyjne).

Pod względem architektury interpretera kodu bajtowego można wyróżnić trzy główne architektury maszyn wirtualnych:

- architekturę stosową, korzystającą ekskluzywnie z jednego lub wielu stosów podczas przetwarzania danych, która charakteryzuje się krótkimi, pod względem zajmowanej pamięci, instrukcjami;
- architekturę rejestrową, korzystającą ekskluzywnie z wielu rejestrów podczas przetwarzania danych, która charakteryzuje się instrukcjami przyjmującymi wiele argumentów określających adresy rejestrów maszyny;
- architektury hybrydowe, łączące dwa powyższe rozwiązania w różnym stopniu.

Pod względem abstrakcyjności maszyny wirtualne można podzielić na dwie główne grupy:

- niskopoziomowe, do których należą maszyny implementujące wyżej wymienione architektury; główną cechą maszyn niskopoziomowych jest obecność stosunkowo nieskomplikowanego kodu bajtowego, który jest przez maszynę interpretowany podczas jej działania;
- wysokopoziomowe, które wymagają niestandardowego traktowania kodu programów; na przykład maszyna redukcji grafowych G-machine wykorzystująca grafową naturę kodu języków funkcyjnych do zrównoleglenia jego ewaluacji, opisana szczegółowo w [6].

Od wyboru architektury interpretera kodu bajtowego bardzo często zależą dostępne funkcjonalności docelowego języka programowania. W celu wybrania odpowiedniej architektury należy przeprowadzić szczegółową analizę porządanych funkcjonalności implementowanego języka i możliwości ich zrealizowania w poszczególnych modelach maszyny wirtualnej. Szczegółowa analiza wpływu języka na możliwość jego zaimplementowania w danej architekturze została zawarta w [9] wraz z praktycznymi wskazówkami dotyczącymi implementacji maszyn wirtualnych, co okazało się niezastąpionym źródłem wiedzy pomocnym przy implementacji ThesisVM.

Interpreter kodu bajtowego zaimplementowany w ramach pracy wykorzystuje niskopoziomową architekturę stosową wykorzystującą wiele stosów oraz niewielki zbiór rejestrów i jest zmodyfikowaną wersją interpretera opisanego w [6, rozdział 4]. Szczegółowy opis implementacji został zawarty w dedykowanej mu sekcji 3 pracy.

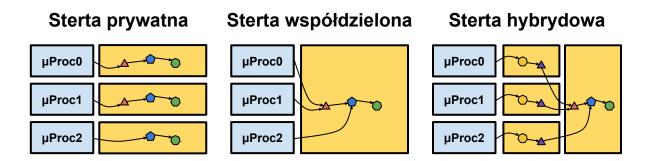
2.4. Zarządzanie pamięcią

Ważnym aspektem architektury maszyny wirtualnej jest sposób w jaki wykorzystuje ona pamięć operacyjną i rozdziela ją pomiędzy procesy w niej działające, czyli architektura wykorzystania sterty (ang. heap architecture).

Rysunek 2.3 przedstawia trzy główne architektury wykorzystania sterty w środowisku wielo-procesowym, gdzie wiele autonomicznych procesów konkuruje o zasób jakim jest pamięć:

- architektura sterty prywatnej, charakteryzująca się zupełną separacją pamięci poszczególnych procesów, co prowadzi do konieczności kopiowania obiektów składających się na wiadomości przesyłane pomiędzy nimi;
- architektura sterty współdzielonej, charakteryzująca się współdzieleniem jednego obszaru pamięci pomiędzy wszystkie procesy, dzięki czemu wiadomości (a także ich części) mogą być współdzielone przez procesy bez konieczności ich kopiowania;

– architektura hybrydowa, mająca za zadanie połączenie zalet obu powyższych rozwiązań przez separację danych lokalnych procesów i współdzielenie danych wiadomości przesyłanych pomiędzy procesami; rozwiązanie to wymaga skomplikowanej, statycznej analizy kodu programów, która nie zawsze może być przeprowadzona.



Rysunek 2.3: Różne modele wykorzystania pamięci maszyn wirtualnych.

Szczegółowa analiza wydajności architektur przedstawionych na rysunku 2.3 w kontekście języka Erlang, do semantyki którego ThesisVM jest bardzo zbliżona, została zawarta w [10]. Na podstawie tej analizy zdecydowano się zastosować architekturę sterty współdzielonej, która minimalizuje problem kopiowania pamięci (*ergo*, spełnia nieformalny cel pracy sformułowany w sekcji 1.1) oraz nie wymaga skomplikowanej statycznej analizy kodu programów. Implementacja pozostawia jednak możliwość późniejszej modyfikacji architektury wykorzystania sterty.

Z problemem architektury wykorzystania sterty ściśle związany jest problem wyboru algorytmu alokacji pamięci. W [11] zawarto obszerne zestawienie algorytmów alokacji pamięci, na podstawie, którego zdecydowano się wykorzystać alokatory kaskadowe, cache'ujące pamięć zwolnionych obiektów w celu optymalizacji alokacji. Implementacja zastosowanego alokatora została zawarta w sekcji 4.

Ostatnim aspektem zarządzania pamięci maszyny wirtualnej jest kolekcja pamięci obiektow nieosiągalnych. Kolektory obiektów nieosiągalnych można podzielić na dwa typy, ze względu na dane, które analizują:

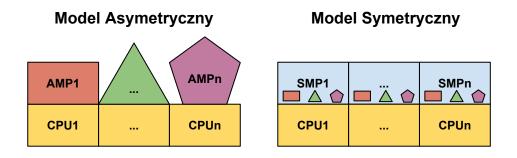
- kolektory śledzące (ang. tracing-GC), które okresowo trawersują zbiór obiektów bazowych (ang. root-set) celem oznaczenia wszystkich obiektów osiągalnych w danej chwili w systemie;
- kolektory zliczające (ang. reference-counting-GC), które na bieżąco zliczają ilość aktywnych referencji do każdego obiektu i natychmiastowo usuwają obiekty, których licznik referencji osiąga zero, co oznacza, że dany obiekt jest nieosiągalny.

Kolektory różnych typów mają bardzo różne charakterystyki wydajnościowe w zależności od architektury wykorzystania sterty zastosowanej w maszynie wirtualnej. Kolektory śledzące przeważnie generują długie pauzy w architekturach współdzielonych, natomiast kolektory zliczające prezentują stały narzut obliczeniowy związany z ciągłą modifykacją liczników referencji. Oczywiście istnieją dobrze poznane metody optymalizacji obu typu algorytmów [12, 13], które zacierają wszelkie różnice w ich charakterystykach wydajnościowych.

W implementacji ThesisVM zdecydowano się wykorzystać mechanizm automatycznej kolekcji "śmieci", oparty o leniwe zliczanie referencji, na podstawie wnikliwej analizy zawartej w [13] oraz w związku z wykorzystaniem podobnych algorytmów kolekcji danych binarnych w standardowej implementacji języka Erlang. Rozwiązanie to zostało szczegółowo opisane w sekcji 4, a implementacja umożliwia późniejsze jej rozszerzenie o dodatkowe optymalizacje. Do alternatywnych rozwiązań należą te zaprezentowane w [14] oraz [15].

2.5. Przetwarzanie współbieżne

Systemy współbieżne często realizują model symetrycznego multiprocessingu (SMP), którego cechą szczególną jest istnienie wielu identycznych jednostek operacyjnych wykonujących jednakowe operacje na różnych zbiorach danych (SMPn na rysunku 2.4).



Rysunek 2.4: Różne modele przetwarzania współbieżnego.

Alternatywnym rozwiązaniem jest model asymetrycznego multiprocessingu (AMP) (AMPn na rysunku 2.4), gdzie dla różnych typów zadań istnieją dedykowane, wyspecjalizowane jednostki operacyjne, takie jak wątki, lub procesy systemu operacyjnego.

Rozwiązania asymetryczne są interesujące ze względu na zupełnie nowe klasy algorytmów, których implementację umożliwiają (na przykład algorytm zarządzania pamięcią

VCGC [15] wykorzystujący trzy asymetryczne wątki), jednak charakteryzują się skomplikowaniem interakcji poszczególnych jednostek operacyjnych a niejednokrotnie także słabą skalowalnością całego rozwiązania.

Model przetwarzania współbieżnego został już przybliżony przy okazji ogólnego opisu architektury ThesisVM na początku rozdziału. Wybrany został model SMP, który w kontekście maszyny wirtualnej ThesisVM polega na zrównolegleniu wielu interpreterów kodu bajtowego operujących na różnych kontekstach procesów (zbiorach rejestrów i danych znajdujących się na ich stosach) w celu osiągnięcia realnej współbieżności interpretowanego kodu.

Dodatkową zaletą modelu SMP jest jego kompatybilność z Modelem Aktorowym [1], którego głównym założeniem jest istnienie autonomicznych aktorów, którzy reagując na zmiany otoczenia dążą do swoich celów porozumiewając się z innymi aktorami za pośrednictwem wysyłania wiadomości [2]. W modelu SMP zastosowanym w maszynie wirtualnej ThesisVM aktorami są poszczególne procesy, które porozumiewają się za pomocą asynchronicznych wiadomości przesyłanych poprzez nieblokujące kolejki FIFO (ang. First In First Out).

Szczegółowy opis implementacji symetrycznego multiprocesora i realizacja Modelu Aktorowego za jego pomocą zostały zawarte w sekcji 5.

3. Interpreter kodu bajtowego

Niniejszy rozdział opisuje implementację interpretera kodu bajtowego ThesisVM. Jak już wspomniano w poprzedniej sekcji, praca implementuje model *Three Instruction Machine*, opisany szczegółowo w [16] oraz [6], wprowadzając do niego szereg modyfikacji.

Three Instruction Machine (TIM) jest nieskomplikowanym modelem maszyny wirtualnej opartym o trzy rejestry, służące do manipulacji danych:

- **IP** wskaźnik *kodu* następnej instrukcji,
- Stack stos kontynuacji skłądających się z wskaźnika do kodu oczekującego na ewaluację oraz kontekstu, w którym należy ów kod ewaluować,
- Env stos będący obecnym kontekstem ewaluacji kodu, który jest analogiczny do leksykalnego zasięgu zmięnnych w kodzie źródłowym programu;

oraz trzy bazowe instrukcje przyjmujące od zera do jednego argumentu, które w zupełności wystarczą do implementacji leniwych, funkcyjnych języków programowania:

- PUSH arg tworzy kontynuację argumentu, która umożliwia jej późniejszą ewaluację w odpowiednim kontekście, odkładając ją na stos Stack,
- TAKE pobiera kontynuację ze stosu Stack i przenosi ją na stos Env rozszerzając obecny kontekst ewaluacji kodu i przygotowując środowisko ewaluacji danej funkcji,
- ENTER arg inicjuje ewaluację kontynuacji wskazywanej przez argument instrukcji odpowiednio modyfikując wartość rejestrów IP i Env.

Dodatkowo, instrukcje TIM posiadają różne typy adresowania argumentów, które wpływają na sposób interpretacji argumentu instrukcji:

- VAL argument jest traktowany jako konkretna wartość,
- CODE argument jest traktowany jako wskaźnik do konkretnej wartości,
- ARG argument jest traktowany jako indeks stosu Env,

Ewaluacja kodu bajtowego TIM przebiega w standardowy sposób. Instrukcje pobierane są z adresu wskazywanego przez wskaźnik następnej instrukcji IP, po czym są dekodowane i wykonywane. Dekodowanie instrukcji polega na pobraniu kodu instrukcji oraz sposobu odresowania argumentu. Ostatnią fazą jest ustalenie konkretnej wartości argumentu na podstawie wcześniej ustalonego adresowania.

```
PUSH ARG 0 # func
ENTER ARG 0 # func
func: TAKE
PUSH ARG 0 # arg
ENTER ARG 1 # func
```

Listing 6: Przykład kodu bajtowego Three Instruction Machine.

Na listingu 6 zawarto przykład kodu bajtowego definicji funkcji func, która przyjmuje jeden argument arg oraz wywołuje samą siebie z tym argumentem. Przed definicją funkcji (dwie instrukcji przed etykietą func:) zawarto także przykładowe wywołanie tej funkcji.

Warto zauważyć, że argumenty przekazywane do funkcji w modelu TIM są ewaluowane leniwie - w przykładzie widniejącym na listingu 6 widać, że argument arg nigdy nie jest ewaluowany, nawet pomimo faktu, że funkcja func przekazuje go do następnego wywołania. Argumenty są ewaluowane dopiero w momencie, gdy maszyna potrzebuje ich konkretnej wartości.

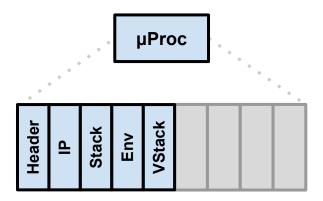
Drugim ważnym spostrzeżeniem jest wsparcie *optymalizacji rekursji ogonowej* modelu TIM - jeśli ostatnią instrukcją kodu ciała funkcji jest wywołanie innej funkcji, to wynikowy kod bajtowy zakończony będzie instrukcją ENTER, która nie wymaga zapisywania adresu powrotnego i tym samym gwarantuje stałą wielkość stosu programu.

Model Three Instruction Machine został wybrany jako podstawa implementacji ThesisVM ze względu na swoją prostotę i niewątpliwe zalety jakie posiada w kontekście implementacji funkcyjnych języków programowania. Istnieje wiele alternatywnych modeli działania maszyn wirtualnych, jak na przykład model SECD [17] oraz jego rekursywny ogonowo wariant TR-SECD [18], czy bardziej adekwatne dla języków z rodziny Lisp modele opisane w [5] oraz [9].

3.1. Modyfikacje i implementacja modelu TIM

Zaprezentowany powyżej model jest bardzo prosty i pomimo swojej niewątpliwej ekspresywności, maszyna wirtualna go implementująca nie byłaby w stanie uruchamiać programów o praktycznym zastosowaniu. W związku z tym, model został rozszerzony o dodatkowy rejestr wskazujący na stos danych "prostych", nie będących kontynuacjami, a

takżge szereg instrukcji implementujących podstawowe instrukcje arytmetyczne, logiczne i związane z implementacją Modelu Aktorowego.



Rysunek 3.1: Schemat stanu maszyny wirtualnej.

Na rysunku 3.1 widnieje schemat rejestrów wykorzystywanych przez interpreter kodu bajtowego. Wymienione rejestry wraz z pozostałymi, opisanymi w następnych sekcjach pracy, składają się na kontekst mikroprocesów ThesisVM.

Rejestr **Header** zawiera informacje o typie procesu oraz metadane kolektora obiektów nieosiągalnych. Konteksty mikroprocesów maszyny ThesisVM są dostępne z poziomu kodu źródłowego, ponieważ są obiektami pierwszej klasy (ang. *first-class object*). Więcej informacji na temat zastosowania tego rejestru zostało zawarte w sekcji 3.3 opisującej implementację obiektów złożonych ThesisVM.

Rejestr **IP** służy do przechowywania wskaźnika następnej instrukcji kodu bajtowego. Jest wykorzystywany w dokładnie taki sam sposób, jak analogiczny rejestr modelu TIM. Rejestry **Env** oraz **Stack** podobnie jak rejestr **IP** również wykorzystywane są zgodnie z opisem modelu TIM.

Ostatni rejestr, **VStack** wskazuje na stos przechowujący dane "proste", czyli obiekty, które nie wymagają ewaluacji przez interpreter i mogą być wykorzystywane przez operacje prymitywne. Funkcjonalność tego stosu nie mogła zostać połączona z funkcjonalnością stosu **Stack**, ponieważ część instrukcji polega na homogeniczności danych znajdujących się na stosie **Stack** - jeśli istnienie na tym stosie danych innych niż kontynuacje zostałoby dozwolone, to część instrukcji wymagałaby kosztownego przeszukiwania i modyfikacji stosu.

Implementacja ThesisVM modyfikuje semantykę trzech bazowych instrukcji TIM:

- NEXT addr arg - jest to bardziej adekwatnie nazwany analog instrukcji PUSH podstawowego modelu TIM, w zależności od typu adresowania argument instrukcja ta tworzy i umieszcza na stosie Stack samo-ewaluującą do wartości argumentu

kontynuację (addr równe VAL), kontynuację składającą się z obecnego kontekstu i wartości wskazywanej przez argument (addr równe CODE) lub wartść kontynuacji znajdującej się na stosie Env (wartość addr równa ARG);

- TAKE podobnie jak w przypadku modelu bazowego, pobiera jedną kontynuację ze stosu kontynuacji Stack i umieszcza ją w obecnym kontekście ewaluacji Env;
- ENTER addr arg w zależności od typu adresacji argumentu odpowiednio modyfikuje wartości rejestrów Env oraz IP podstawiając wartość IP na wartość argumentu
 (addr równe CODE), lub ewaluując kontynuację znajdującą się na stosie Env (wartość
 addr równa ARG);

oraz wprowadza kilka nowych instrukcji służących do obsługi dodatkowego rejestru i operacji prymitywnych z nim związanych:

- PUSH arg jest to prosta instrukcja, której jedynym zadaniem jest umieszczenie argumentu na stosie VStack;
- PRIMOP arg wykonuje operację prymitywną o identyfikatorze równym wartości argumentu. Więcej informacji o implementacji operacji prymitywnych zawarto w sekcji 3.5;
- COND arg jest to instrukcja warunkowa, która sprawdza wartość znajdującą się na wierzchu stosu VStack i w zależności od jej wartości wybiera jedną z dwóch gałęzi kodu wskazywanych przez argument i ustawia jej wartość jako nową wartość rejestru IP;
- SPAWN arg jest to instrukcja związana z implementacją Modelu Aktorowego, tworzy ona nowy kontekst mikroprocesu ThesisVM i aranżuje ewaluację kontynuacji znajdującej się na stosie Env pod indeksem równym wartości argumentu instrukcji (arg) przekazując jej jako parametr wartość znajdującą się na szczycie stosu VStack. Tak zaaranżowany kontekst mikroprocesu jest następnie dodawany do kolejki uruchomieniowej jednego z symetrycznych multiprocesorów wybranego zgodnie z zasadami równoważenia obciążenia (opisanymi w sekcji 5.2);
- HALT instrukcja ta usypia proces na czas nieokreślony efektywnie kończąc jego działanie. Tak zatrzymany proces następnie podlega kolekcji przez kolektor obiektów nieosiągalnych, ponieważ mogą istnieć referencje nań wskazujące, które są wykorzystywane przez inne procesy.

3.2. Implementacja obiektów prostych

Dane programów w maszynie ThesisVM reprezentowane są za pomocą dwóch rodzajów obiektów - obiektów "prostych" oraz obiektów złożonych. Rysunek 3.2 zawiera schemat reprezentacji obiektów prostych, które należą do jednego z trzech wspieranych typów podstawowych: POINTER, FLOATING lub INTEGER.



Rysunek 3.2: Schemat reprezentacji obiektów prostych ThesisVM.

Implementacja przechowuje dane obiektów prostych w strukturze o wielkości jednego słowa procesora (64 bity w obecnej implementacji maszyny wirtualej przystosowanej do architektury $\mathbf{x86}_{64}$), która zapewnia dostęp do dwóch pól identyfikujących odpowiednio 61-bitową wartość przechowywaną w strukturze oraz 3-bitowy typ, do którego owa wartość należy.

Wartość przechowywane są wraz z informacją o ich typie, w celu umożliwienia implementacji języków dynamicznie typowanych oraz ułatwienia pracy kolektora obiektów nieosiągalnych - dzięki informacji o typie może on precyzyjnie określić, czy dany obiekt jest referencją, czy też nie.

Typy obiektow prostych przechowywane są w trzech najmniej znaczących bitach (ang. least significant bits, LSB) reprezentacji, umożliwiając implementację ośmiu różnych typów podstawowych, zgodnie ze szczegółowym opisem zawartym w [19]. Reprezentacja taka posiada szereg zalet począwszy od kompaktowości, przez brak konieczności alokacji pamięci dla typów podstawowych, kończąc na wielu ciekawych optymalizacjach, które umożliwia.

Na przykład, jeśli alokator maszyny wirtualnej wymusi wyrównywanie pamięci (ang. alignment) do wielkości słowa procesora, to trzy najmniej znaczące bity (na architekturze 64-bitowej) reprezentacji wskaźników zawsze będą zerowe. W związku z tym, zerem można reprezentować typ wskaźnikowy obiektow prostych ThesisVM (typ POINTER), co umożliwia wykorzystywanie ich reprezentacji bezpośrednio, bez konieczności przeprowadzenia operacji bitowego maskowania.

Podobne optymalizacje mogą zostać zastosowane w przypadku reprezentacji obiektów numerycznych. Na przykład, w celu dodania dwóch liczb całkowitych (o typie INTEGER) można posłużyć się ostatnią zależnością zaprezentowaną na listingu 7 zamiast wielokrotnie wykorzystywać kosztowne operacje tag i untag, które realizują przejścia pomiędzy reprezentacją wewnętrzną obiektów maszyny wirtualnej a reprezentacją języka jej implementacji.

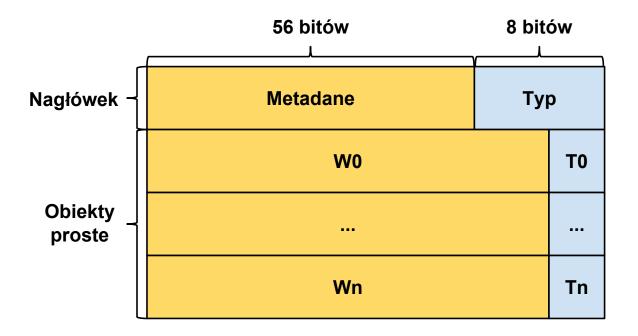
```
result = tag(TVMValue.INTEGER, (untag(a) + untag(b)));
result = a.rawValue + b.rawValue - TVMValue.INTEGER;
```

Listing 7: Optymalizacja dodawania liczb całkowitych.

Wiele ciekawych optymalizacji związanych ze sposobem reprezentacji typów obiektów zostało zawarte w [19].

3.3. Implementacja obiektów złożonych

Ważnym elementem każdego języka programowania są złożone struktury danych takie jak listy lub drzewa. Rysunek 3.3 prezentuje schemat reprezentacji obiektów złożonych ThesisVM, które służą do budowy takich struktur danych.



Rysunek 3.3: Schemat reprezentacji obiektów złożonych ThesisVM.

Obiekty te składają się z wielu słów procesora ułożonych kolejno w pamięci. Pierwszym słowem składającym się na obiekt złożony jest jego **nagłówek**, który zawiera między innymi ośmio-bitowy identyfikator typu obiektu oraz metadane kolektora obiektów nieosiągalnych.

Podobnie jak w przypadku obiektów prostych, informacja o typie jest wykorzystywana do implementacji języków dynamicznie typowanych oraz w celu ułatwienia pracy kolektora "śmieci". Identyfikator typu obiektu jest jednak znacznie większy pozwalając na reprezentację 256 różnych wartości, a co za tym idzie 256 różnych typów. Obecna implementacja nie wykorzystuje potencjału dłuższego identyfikatora typu w pełni, ale w przyszłości może zostać rozwinięta, na przykład w celu umożliwienia definiowania nowych typów danych.

Dodatkowym atutem stosowania nagłówka jest fakt, że wszystkie obiekty złożone ThesisVM mogą być traktowane w jednolity sposób za pośrednictwem wskaźników do owego nagłówka. Informacja o typie obiektu w nim zawarta może zostać wykorzystana do łatwego określenia faktycznej struktury obiektu znajdującego się w pamięci. Metoda ta została szeroko opisana w [19] i jest standardowym rozwiązaniem wielu maszyn wirtualnych.

Po nagłówku występują właściwe dane w postaci n obiektów prostych, gdzie n jest dowolną liczbą naturalną. Ich zawartość Wn oraz typy Tn zależą w dużej mierze od typu całego obiektu złożonego, ale w ogólności podlegają wszystkim zasadom, którym podlegają obiekty proste.

Obecna implementacja definiuje 4 typy obiektów złożonych: PAIR, CLOSURE, SYMBOL oraz UPROC.

Pary składają się z nagłówka oraz dwóch obiektów prostych odpowiadających odpowiednio pierwszemu i drugiemu elementowi pary. Pary są wykorzysytwane do implementacji list, które z kolei są podstawowymi strukturami danych języka TVMIR, podobnie jak w innych językach z rodziny Lisp.

Obiekty funkcyjne, zwane czasami domknięciami leksykalnymi (ang. *closures*), służą do reprezentowania skompilowanych funkcji TVMIR oraz kontynuacji będących podstawą działania modelu TIM. W obu przypadkach obiekty funkcyjne składają się z dwóch obiektów prostych odpowiadających kolejno rejestrowi IP oraz stosowi Env.

Różnica pomiędzy skompilowanymi funkcjami oraz kontynuacjami sprowadza się do zestawu instrukcji zawartego w komponencie IP obiektu funkcyjnego - funkcje przyjmujące parametry wymagają pobrania ich wartości za pomocą instrukcji TAKE.

Symbole również składają się z nagłówka oraz dwóch obiektów prostych, które oznaczają odpowiednio wskaźnik na zewnętrzny fragment pamięci zawierający tekstową reprezentację symbolu i długość owej reprezentacji. Reprezentacja symboli została pomyślana w taki sposób, by umożliwiała bezpośrednie mapowania reprezentacji tekstowej na dostępny

w języku D typ danych **string**, co znacząco ułatwia obsługę symboli w implementacji maszyny wirtualnej.

Ostatnim dostępnym typem danych ThesisVM jest **deskryptor mikroprocesu**. Deskryptory te są obiektami pierwszej klasy, co oznacza, że są w pełni dostępne dla użytkownika ThesisVM. Konteksty mikroprocesów składają się z nagłówka oraz ośmiu obiektów prostych, z których cztery pierwsze odpowiadają opisanym w poprzedniej sekcji rejestrom maszyny wirtualnej, a cztery następne zawierają dane wykorzystywane przez pozostałe moduły maszyny wirtualnej. Obiekty te zostały opisane w sekcjach 4 oraz 5.

3.4. Implementacja i obsługa kodu bajtowego

Instrukcje kodu bajtowego ThesisVM dzielą reprezentację z obiektami złożonymi. Podobnie jak pary składają się z nagłówka obiektu oraz dwóch obiektów prostych, z których pierwszy określa identyfikator instrukcji oraz sposób adresowania argumentu, a drugi przechowuje wartość argumentu instrukcji. Dostępne instrukcje kodu bajtowego zostały już opisane w sekcji 3.1.

Reprezentacja kodu bajtowego wykorzystywana obecnie w maszynie wirtualnej niestety jest sub-optymalna. Alternatywnym rozwiązaniem mogło by być zastosowanie reprezentacji opartej o obiekty proste polegającej na przechowywaniu identyfikatorów instrukcji w najbardziej znaczącym bajcie obiektu.

Dekodowanie argumentu instrukcji wymagałoby wówczas jedynie przeskalowania pozostałych bajtów obiektu prostego celem odtworzenia rzeczywistej jego wartości, lub w przypadku niewielkich liczb całkowitych i typu wskaźnikowego, jedynie zastosowania masek bitowych.

Instrukcje pobierane są ze *strumienia kodu bajtowego* wskazywanego przez rejestr IP. W obecnej implementacji strumień kodu bajtowego zrealizowany jest jako lista pojedynczo wiązana zbudowana z obiektów złożonych ThesisVM - par.

Reprezentacja ta została wybrana ze względu na charakter języka TVMIR (jest to język z rodziny Lisp) oraz przez wzgląd na podobieństwo to obsługi stosów Stack, Env oraz VStack, które również zostały zrealizowane w oparciu o listy pojedynczo wiązane. W przyszłości implementacja ta może zostać zastąpiona rozwiązaniem szybszym, niekoniecznie opartym o listy (więcej informacji na ten temat zawarto w sekcji 6.4).

Po przechwyceniu pierwszego elementu listy wskazywanej przez rejestr IP następuje ustalenie identyfikatora instrukcji, sposobu adresowania argumentu oraz samej wartości argumentu instrukcji. Następnie interpreter ewaluuje instrukcję zgodnie z regułami opisanymi w sekcji 3.1.

3.5. Implementacja operacji prymitywnych

Operacje wbudowane, takie jak arytmetyka, czy funkcje związane z implementacją Modelu Aktorowego zostały zrealizowane w oparciu o rejestr VStack - argumenty operacji prymitywnych są pobierane ze stosu a wartości przez nie zwracane są nań odkładane. Listing 8 zawiera ogólny algorytm implementacji operacji prymitywnych ThesisVM.

```
arg0 = typecheck(t0, pop(uProc.vstack));

// ...

argN = typecheck(tN, pop(uProc.vstack));

// Obliczenia charakterystyczne dla danej operacji.
result = compute(arg0, ..., argN);

push(uProc.vstack, result);
```

Listing 8: Ogólny algorytm implementacji operacji prymitywnych ThesisVM.

Instrukcja wykonujące operacje primitywne, PRIMOP id, wykorzystuje metodę LUT (ang. look-up table) w celu skorelowania identyfikatora operacji prymitywnej i fragmentu kodu odpowiedzialnego za jej wykonanie - wykonanie tej instrukcji polega na przekazaniu przepływu sterowania do odpowiedniej funkcji znajdującej się w tablicy operacji prymitywnych.

Dostępne operacje prymitywne to w dużej mierze podstawowe operacje arytmetycznologiczne oraz funkcje typowe dla języków z rodziny Lisp, takie jak cons, car, czy cdr (więcej informacji można znaleźć w [5]). Lista wszystkich dostępnych operacji prymitywnych została zawarta w dodatku B.

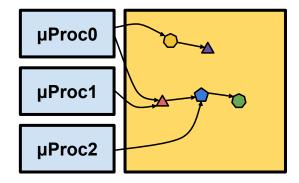
Ponownie uwagę można zwrócić na podobieństwo traktowania operacji prymitywnych do języka Core Erlang [8]. Podobieństwo to nie jest przypadkowe, a wybrany sposób reprezentacji i działania operacji prymitywnych został zaimplementowany w taki sposób, by w przyszłości umożliwić łatwe rozszerzenie implementacji maszyny wirtualnej ThesisVM oraz wsparcie pełni języka Core Erlang.

4. Model zarządzania pamięcią

Niniejsza sekcja opisuje implementację modelu zarządzania pamięcią zastosowanego w maszynie wirtualnej ThesisVM, na który składa się architektura wykorzystania pamięci, algorytm alokacji obiektów oraz algorytm kolekcji obiektów nieosiągalnych. Wstępny opis wybranego modelu pamięci oraz motywacja tego wyboru zostały zawarte w sekcji 2.4.

4.1. Architektura współdzielonej sterty

Na rysunku 4.1 zawarto schemat architektury sterty wykorzystanej w ThesisVM. Jest to architektura współdzielonej sterty, w której każdy z mikroprocesów alokuje obiekty na własny użytek. Obiekty te lub ich części mogą być następnie współdzielone pomiędzy mikroprocesami w wyniku przesyłania wiadomości.



Rysunek 4.1: Model współdzielonej pamięci ThesisVM.

Kluczową zaletą wybranej architektury wykorzystania pamięci jest brak konieczności kopiowania danych przesyłanych pomiędzy mikroprocesami. Ponieważ wszystkie dane są zaalokowane w jednej puli pamięci, przesyłanie wiadomości sprowadza się jedynie do przekazania wkaźników do owych wiadomości pomiędzy mikroprocesami, co jest operacją o złożoności czasowej i pamięciowej rzędu O(1).

Alternatywne rozwiązania polegające na separacji danych mikroprocesów poprzez wykorzystanie osobnych puli pamięci dla każdego mikroprocesu nie posiadają tej zalety i wymagają kosztownego kopiowania wszystkich przesyłanych wiadomości, co w przypadku wzmożonej komunikacji pomiędzy mikroprocesami powoduje znaczną degradację wydajności.

Kolejną ważną zaletą wybranej architektury jest łatwość jej implementacji z wykorzystaniem sterty procesu maszyny wirtualej, zarządzanej przez system operacyjny, na którym jest ona uruchomiona. Pozwala to na wykorzystanie gotowego, standardowego interfejsu alokacji udostępnianego przez system operacyjny.

Do niewątpliwych wad zastosowanej architektury należą wyzwania, jakie stawia ona algorytmom kolekcji obiektów nieosiągalnych. Zadaniem tych algorytmów jest automatyczne zwolnienie nieużywanej pamięci mikroprocesów, co w wyniku współdzielenia danych jest znacznie utrudnione i może prowadzić do długich przerw w działaniu maszyny wirtualnej przeznaczonych na cykle kolekcji "śmieci".

Kolejną wadą architektury współdzielonej sterty jest fakt, że pamięć mikroprocesu nie może zostać od razu i w całość zwolniona po zakończeniu jego działania. Ponieważ dane mogą być wciąż wykorzystywane przez inne mikroprocesy, po zakończeniu działania jednego z nich musi zostać wykonany pełen cykl kolekcji obiektów nieosiągalnych.

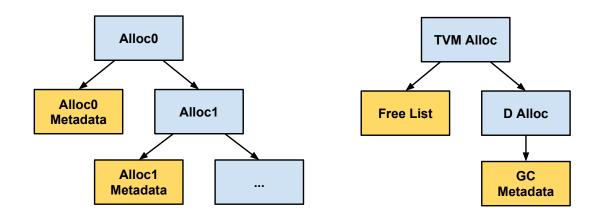
Szczegółowa analiza zalet i wad architektury współdzielonej sterty w kontekście implementacji języka Erlang została zawarta w [10].

4.2. Implementacja alokatora obiektów

Maszyna wirtualna ThesisVM wykorzystuje algorytm kaskadowych alokatorów polegający na kompozycji wielu algorytmów alokacji obiektów wraz z wykorzystywanymi przez nie metadanymi w taki sposób, by umożliwić algorytmowi na danym poziomie odwoływanie się do algorytmu na niższym poziomie. Schematyczna reprezentacja takiego rozwiązania została zawarta na rysunku 4.2.

W momencie, gdy algorytm na danym poziomie ustali, że nie jest w stanie obsłużyć żądania użytkownika przepływ sterowania zostanie przekazany do algorytmu leżącego poziom niżej, gdzie obsługa żądania będzie kontynuowana. Dzięki takiemu rozwiązaniu możliwe jest zaimplementowanie szeregu ciekawych algorytmów alokacji i dowolne ich komponowanie.

Obecnie, implementacja ThesisVM wykorzystuje dwu-poziomowy alokator składający się z algorytmów **TVM Alloc** oraz **D Alloc**, który został zaprezentowany ra rysunku 4.2.

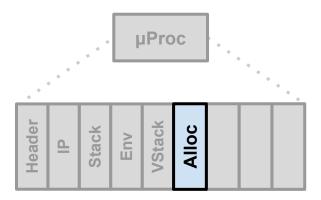


Rysunek 4.2: Schemat kaskadowych alokatorów wykorzystanych w ThesisVM.

D Alloc jest standardowym interfejsem alokatora języka D, który wykorzystuje metadane kolektora obiektów nieosiągalnych języka D i udostępnia wyrównaną do słowa procesora (8 bajtów na architekturze x86_64) pamięć przezeń zarządzaną. Wybór tego algorytmu zostanie umotywowany w sekcji 4.4.

Alternatywnym rozwiązaniem dla D Alloc byłoby wykorzystanie interfejsu manualnego zarządzania pamięcią poprzez wykorzystanie funkcji malloc i free ze standardowej biblioteki języka C, która wchodzi w skład standardowej biblioteki języka D.

TVM Alloc jest dodatkowym algorytmem alokacji zbudowanym w oparciu o interfejs D Alloc, który dodatkowo zapewnia buforowanie (ang. *caching*) pamięci za pomocą listy niedawno zwolnionych obiektów, która jest przeszukiwana w pierwszej kolejności podczas żądania alokacji.



Rysunek 4.3: Schemat rejestrów wymaganych przez implementację alokatora obiektów.

Każdy mikroproces posiada własną listę niedawno zwolnionych obiektów (rysunek 4.3), co zapewnia lepsze wykorzystanie pamięci przez zwiększenie lokalności referencji - obiekty

K. Rzepecki Implementacja maszyny wirtualnej dla funkcyjnych języków programowania . . .

zwalniane podczas działania mikroprocesu trafiają na listę niedawno zwolnionych obiektów i bardzo szybko są wykorzystywane powtórnie bez konieczności odwoływania się do alokatorów z niższych poziomów.

Wykorzystanie listy niedawno zwolnionych obiektów do buforowania alokacji umożliwia także zaimplementowanie zupełnie nowej klasy algorytmów kolekcji obiektów nieosiągalnych w oparciu o *leniwe cykle kolekcji*. Algorytm taki został opisany w następnej sekcji.

Zagadnienie alokacji pamięci jest bardzo rozległe i w kontekście języków programowania zależy od wielu różnych czynników, takich jak charakterystyki zużycia pamięci konkretnych programów, wielkości alokowanych obiektów, czy czasy ich życia. Przegląd [11] zawiera szczegółową analizę wydajności wielu różnych algorytmów alokacji pamięci w warunkach symulowanych oraz dla rzeczywistych programów, co było niezastąpionym źródłem wiedzy pomocnym przy wyborze i implementacji algorytmu alokacji obiektów maszyny wirtualnej ThesisVM.

4.3. Kolekcja obiektów nieosiągalnych

Różne podejścia do problemu automatycznego zwalniania nieużywanej pamięci zostały już opisane w sekcji 2.4, której konkluzją był wybór algorytmu **zliczania referencji** jako głównego algorytmu kolekcji obiektów nieosiągalnych.

Algorytm zliczania referencji polega na przechowywaniu i modyfikacji liczników aktywnych referencji wskazujących na dany obiekt w pamięci. Liczniki te przechowywane są w nagłówkach obiektów, dzięki czemu algorytm jest w stanie zdecydować, czy konkretny obiekt jest w dalszym ciągu w użyciu jedynie na podstawie wkaźnika na jego nagłówek.

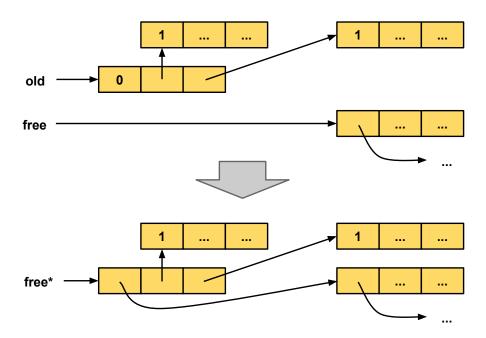
Liczniki modyfikowane są podczas tworzenia nowych i usuwania istniejących referencji - stworzenie nowej referencji do konkretnego obiektu powoduje inkrementację jego licznika referencji, natomiast usunięcie istniejącej referencji powoduje jego dekrementację. W momencie, gdy wartość licznika osiągnie zero obiekt jest uznawany za nieosiągalny i następuje zwolnienie jego pamięci ora usunięcie wszystkich referencji wchodzących w jego skład.

Wariant algorytmu zaimplementowany w maszynie wirtualnej ThesisVM to tak zwane leniwe zliczanie referencji, którego implementacja jest możliwa dzięki zastosowaniu alokatora buforującego zwalniane obiekty. Algorytm ten polega na opóźnieniu usuwania referencji wchodzących w skład usuwanego obiektu do czasu aż jego pamięć zostanie powtórnie wykorzystana.

Modyfikacja ta jest bardzo prosta i pozwala osiągnąć dużo lepsze charakterystyki czasowe kolekcji obiektów nieosiągalnych kosztem zwiększenia ogólnego zużycia pamięci - obiekty nie są zwalniane natychmiastowo, a dopiero przy następnej alokacji. Dokładne

badanie wpływu opisanej modyfikacji algorytmu zliczania referencji na zużycie pamięci zostało przedstawione w [20].

Rysunek 4.4 zawiera schemat dealokacji obiektu z wykorzystaniem opisanego powyżej algorytmu.

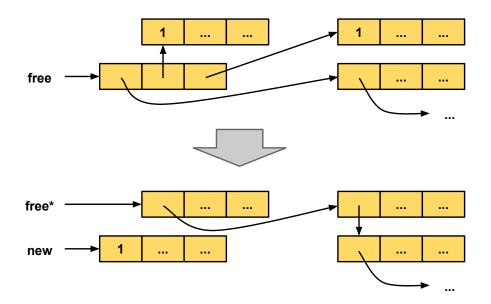


Rysunek 4.4: Schemat działania zwalniania pamięci obiektów.

Obiekt old, którego licznik referencji osiągnął wartość 0 w wyniku usunięcia ostatniej aktywnej referencji zostaje przeniesiony do listy niedawno zwolnionych obiektów free. Lista ta wykorzystuje ów licznik do przechowywania wskaźnika na następny element listy, dzięki czemu możliwe jest zachowanie danych obiektu bez zmian w celu późniejszego, leniwego ich usunięcia podczas następnej alokacji (rysunek 4.5).

Alokacja nowego obiektu **new** polega na pobraniu pierwszego elementu listy niedawno zwolnionych obiektów **free** oraz usunięciu wszystkich referencji wchodzących w jego skład. Pociąga to za sobą dekrementację liczników referencji obiektów, na które owe referencje wskazują i ewentualną dealokację tych obiektów, jeśli ich liczniki osiągnęły wartość 0. W przypadku, gdy lista **free** jest pusta tworzony jest zupełnie nowy obiekt, który jest dodawany do wspólnej puli pamięci.

W przypadku języków programowania wspierających przetwarzanie współbieżne algorytm dodatkowo komplikuje konieczność wykorzystywania operacji atomowych na licznikach referencji obiektów, które mogą być modyfikowane jednocześnie przez wiele wątków sprzętowego procesora. Dodatkowo ważne jest wykorzystanie barier pamięci, które uniemożliwiają zmiany kolejności wykonywania operacji na pamięci, co jest częstym zabiegiem optymalizacyjnym w nowoczesnych procesorach.



Rysunek 4.5: Schemat działania alokacji pamięci nowych obiektów.

Konieczność stosowania operacji atomowych i barier pamięci powoduje nieznaczny spadek wydajności maszyny wirtualnej, który jednak jest wart odnotowania. Implementacja kolektora "śmieci" ThesisVM wykorzystuje wbudowane w język D kwalifikatory typów shared, które gwarantują stosowanie operacji atomowych i barier pamięci w stategicznych miejscach.

Implementacja optymalizuje także modyfikacje liczników referencji przez ich opóźnienie lub całkowite wyeliminowanie (arg. deferred reference counting), jeśli nie są konieczne - na przykład w przypadku transferu referencji pomiędzy dwoma obiektami.

Jest to potencjalnie niebezpieczna technika wymagająca manualnego dekrementowania i inkrementowania liczników referencji za pomocą funkcji use oraz free. Alternatywnym rozwiązaniem jest wykorzystanie inteligentnych wskaźników (ang *smart pointers*), które gwarantują deterministyczną inkrementację i dekrementację liczników.

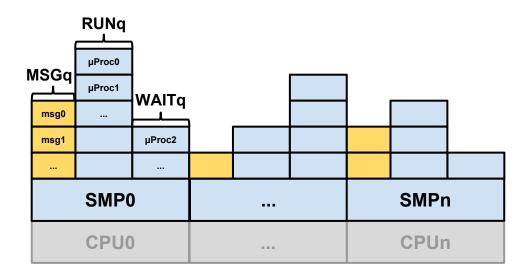
Więcej możliwych usprawnień algorytmu kolekcji obiektow nieosiągalnych za pomocą zliczania referencji zostało przedstawionych w [13] oraz [12].

4.4. Kolekcja obiektów cyklicznych

- Opisać, że obiekty cykliczne występują rzadka (tylko procesy przez (self)).
- Wspomnieć o możliwości zaimplementowania zapasowego stop-the-world GC.
- Wspomnieć o możliwości cyklicznego uruchamiania D'owego GC.

5. Model przetwarzania współbieżnego

– Opisać bardziej szczegółowo model SMP.



Rysunek 5.1: Schemat symetrycznego multiprocesora ThesisVM.

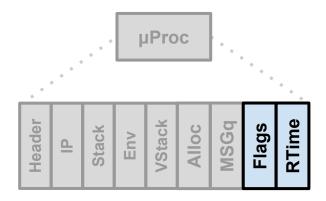
Opisać bardziej szczegółowo Model Aktorowy i asynchroniczne przekazywanie wiadomości. [1, 2]

5.1. Implementacja symetrycznego multiprocessingu

- Opisać bardziej szczegółowo implementację SMP
- Opisać spawnowanie procesów.
- Co SMP robi podczas interpretacji kodu.

5.2. Harmonogramowanie procesów

- Opisać Completely Fair Scheduler. [21]
- Opisać sposób harmonogramowania procesów (brak load-balancingu, losowy spawn).
- Opisać implementację prymitywu sleep oraz sleep-table.
- Opisać wiadomości kontrolne.

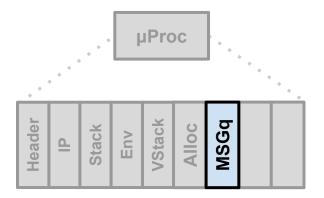


Rysunek 5.2: Schemat rejestrów wymaganych przez usprawnienia hanmonogramowania SMP.

– Opisać możliwe usprawnienia (load-balancing i dzielenie zużycia).

5.3. Implementacja Modelu Aktorowego

- Opisać powstawanie procesów i prymityw spawn.
- Opisać logiczną autonomiczność procesów (brak mutacji = inne procesy nie mogą ingerować).
- Opisać sposób porozumiewania się procesów (kolejki nieblokujące). [22, 23]
- Opisać implementację kolejek nieblokujących (+ weryfikacja poprawności). [22, 24]
 Opisać wykorzystanie CAS i problem ABA.
- Opisać zmiany wprowadzone w stanie maszyny wirtualnej (dodatkowe rejestry).

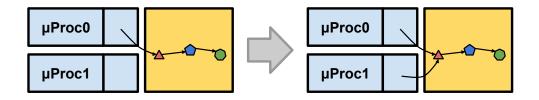


Rysunek 5.3: Schemat rejestrów wymaganych przez implementację Modelu Aktorowego.

- Opisać krótko wady i możliwe usprawnienia zastosowanego rozwiązania (dynamic size, wait-free, optimistic FIFO). [23, 25, 26]
- Opisać krótko alternatywne podejścia (synchroniczne przekazywanie wiadomości kanały, locki/mutexy/semafory).

5.4. Implementacja przesyłania wiadomości

- Opisać implementację prymitywów send oraz receive.
- Zwrócić uwagę na konieczność wykorzystania operacji atomowych oraz barier pamięci.
- Snippet kodu przesyłającego wiadomość.



Rysunek 5.4: Schemat działania przesyłania wiadomości.

- Opisać co dzieje się podczas wysyłania wiadomości.
- Opisać sposób pobierania wiadomości z kolejki.
- Zwrócić uwagę na fakt, że problem kopiowania został zniwelowany kosztem lekkich barier pamięci.

6. Podsumowanie

- Opisać co udało się zrobić.
- Opisać czego nie udało się zrobić (+ możliwe usprawnienia).

6.1. Interpreter kodu bajtowego

- Opisać brak apdejtowania już obliczonych wartości i dać link do sec:futuredevelopment.
- Opisać możliwość zastosowania lepszej reprezentacji bytecodu i bytecode threading.

6.2. Kolektor obiektów nieosiągalnych

- Przeanalizować szybkość, pauzy, zużycie pamięci.

6.3. Przetwarzanie współbieżne

 Przeanalizować szybkość przesyłania wiadomości/konieczność czekania procesów, wielkość kolejek wiadomości.

6.4. Kierunki przyszłego rozwoju

Opisać plany na przyszły rozwój projektu (priorytet procesów, load balancing SMP, wsparcie dla Core Erlang, bytecode threading, przebiegi optymalizacyjne podczas kompilacji, umożliwienie dystrybucji na wiele maszyn, zapasowy kolektor śmieci cyklicznych, opcja wykorzystania sterty prywatnej i autonomicznego alokatora, natywna kompilacja JIT, wektory, data-level parallelism, optymalizacja wykorzystania stosu, hardłerowa implementacja interpretera kodu bajtowego).

Bibliografia

- [1] C. Hewitt, P. Bishop, and R. Steiger, "A universal modular actor formalism for artificial intelligence," in *Proceedings of the 3rd International Joint Conference on Artificial Intelligence*, IJCAI'73, (San Francisco, CA, USA), pp. 235–245, Morgan Kaufmann Publishers Inc., 1973.
- [2] W. D. Clinger, "Foundations of actor semantics," tech. rep., Cambridge, MA, USA, 1981.
- [3] A. Alexandrescu, The D Programming Language. Pearson Education, 2010.
- [4] J. Armstrong, R. Virding, C. Wikström, and M. Williams, Concurrent Programming in ERLANG (2Nd Ed.). Hertfordshire, UK, UK: Prentice Hall International (UK) Ltd., 1996.
- [5] H. Abelson and G. J. Sussman, Structure and Interpretation of Computer Programs. Cambridge, MA, USA: MIT Press, 2nd ed., 1996.
- [6] S. P. Jones and D. Lester, *Implementing functional languages: a tutorial*. Prentice Hall, 1992. Free online version.
- [7] R. Carlsson, "An introduction to Core Erlang," in *In Proceedings of the PLI'01 Erlang Workshop*, 2001.
- [8] R. Carlsson, B. Gustavsson, E. Johansson, T. Lindgren, S.-O. Nyström, M. Pettersson, and R. Virding, "Core Erlang 1.0.3 language specification," tech. rep., Department of Information Technology, Uppsala University, Nov. 2004.
- [9] G. L. Steele Jr and G. J. Sussman, "The art of the interpreter of the modularity complex (parts zero, one, and two)," 1978.
- [10] J. Wilhelmsson, Efficient Memory Management for Message-Passing Concurrency — part I: Single-threaded execution. Licentiate thesis, Department of Information Technology, Uppsala University, May 2005.

44 BIBLIOGRAFIA

[11] P. R. Wilson, M. S. Johnstone, M. Neely, and D. Boles, "Dynamic storage allocation: A survey and critical review," 1995.

- [12] R. Shahriyar, S. M. Blackburn, and D. Frampton, "Down for the count? getting reference counting back in the ring," in *Proceedings of the 2012 International Symposium on Memory Management*, ISMM '12, (New York, NY, USA), pp. 73–84, ACM, 2012.
- [13] D. F. Bacon, P. Cheng, and V. T. Rajan, "A unified theory of garbage collection," in Proceedings of the 19th Annual ACM SIGPLAN Conference on Object-oriented Programming, Systems, Languages, and Applications, OOPSLA '04, (New York, NY, USA), pp. 50–68, ACM, 2004.
- [14] J. Armstrong and R. Virding, "One pass real-time generational mark-sweep gar-bage collection," in IN INTERNATIONAL WORKSHOP ON MEMORY MANA-GEMENT, pp. 313–322, Springer-Verlag, 1995.
- [15] L. Huelsbergen and P. Winterbottom, "Very concurrent mark-&-sweep garbage collection without fine-grain synchronization," in *Proceedings of the 1st International Symposium on Memory Management*, ISMM '98, (New York, NY, USA), pp. 166–175, ACM, 1998.
- [16] J. Fairbairn and S. Wray, "TIM: A simple, lazy abstract machine to execute super-combinators," in *Proc. Of a Conference on Functional Programming Languages and Computer Architecture*, (London, UK, UK), pp. 34–45, Springer-Verlag, 1987.
- [17] D. Van Horn and M. Might, "Abstracting abstract machines," in *Proceedings of the* 15th ACM SIGPLAN International Conference on Functional Programming, ICFP '10, (New York, NY, USA), pp. 51–62, ACM, 2010.
- [18] J. D. Ramsdell, "The Tail-Recursive SECD Machine," *Journal of Automated Reasoning*, vol. 23, no. 1, pp. 43–62, 1999.
- [19] D. Gudeman, "Representing type information in dynamically typed languages," 1993.
- [20] H.-J. Boehm, "The space cost of lazy reference counting," in *Proceedings of the* 31st ACM SIGPLAN-SIGACT Symposium on Principles of Programming Languages, POPL '04, (New York, NY, USA), pp. 210–219, ACM, 2004.
- [21] C. S. Pabla, "Completely fair scheduler," Linux J., vol. 2009, Aug. 2009.
- [22] M. M. Michael and M. L. Scott, "Simple, fast, and practical non-blocking and blocking concurrent queue algorithms," in *Proceedings of the Fifteenth Annual ACM Symposium on Principles of Distributed Computing*, PODC '96, (New York, NY, USA), pp. 267–275, ACM, 1996.

BIBLIOGRAFIA 45

[23] M. Herlihy, V. Luchangco, P. Martin, and M. Moir, "Dynamic-sized lock-free data structures," tech. rep., 2002.

- [24] L. Groves, "Verifying Michael and Scott's lock-free queue algorithm using trace reduction," in *Proceedings of the Fourteenth Symposium on Computing: The Australasian Theory Volume 77*, CATS '08, (Darlinghurst, Australia, Australia), pp. 133–142, Australian Computer Society, Inc., 2008.
- [25] A. Kogan and E. Petrank, "Wait-free queues with multiple enqueuers and dequeuers," in *Proceedings of the 16th ACM Symposium on Principles and Practice of Parallel Programming*, PPoPP '11, (New York, NY, USA), pp. 223–234, ACM, 2011.
- [26] E. Ladan-Mozes and N. Shavit, "An optimistic approach to lock-free FIFO queues," 2004.

46 BIBLIOGRAFIA

A. Przykładowe programy

A.1. Interfejs i użytkowanie ThesisVM

- Opisać sposób uruchamiania maszyny wirtualnej.
- A.2. "Hello world!"
- A.3. Funkcje i operacje prymitywne
- A.4. Factorial
- A.5. Fibonacci
- A.6. Współbieżne "Hello world!"
- A.7. Współbieżne obliczanie silni

A.7.	Współbieżne	obliczanie	silni
------	-------------	------------	-------

B. Spisy wbudowanych operatorów i funkcji

Spis operatorów wbudowanych

- + pobiera dwa parametry typu numerycznego i zwraca wynik ich dodawania.
- - pobiera dwa parametry typu numerycznego i zwraca wynik ich odejmowania.
- * pobiera dwa parametry typu numerycznego i zwraca wynik ich mnożenia.
- / pobiera dwa parametry typu numerycznego i zwraca wynik ich dzielenia.
- mod pobiera dwa parametry typu numerycznego i zwraca wynik przeprowadzenia na nich operacji modulo.
- pow pobiera dwa parametry typu numerycznego i zwraca wynik przeprowadzenia na nich operacji potęgowania.
- inc pobiera jeden parametr typu numerycznego i zwraca jego wartość inkrementowaną o 1.
- dec pobiera jeden parametr typu numerycznego i zwraca jego wartość dekrementowaną o 1.
- = pobiera dwa parametry typu numerycznego i zwraca 1 w przypadku, gdy są równe, lub pustą listę w przeciwnym przypadku.
- < pobiera dwa parametry typu numerycznego i zwraca 1 w przypadku, gdy pierwszy
 z nich ma mniejszą wartość od drugiego, lub pustą listę w przeciwnym przypadku.
- > pobiera dwa parametry typu numerycznego i zwraca 1 w przypadku, gdy pierwszy
 z nich ma większą wartość od drugiego, lub pustą listę w przeciwnym przypadku.
- <= pobiera dwa parametry typu numerycznego i zwraca 1 w przypadku, gdy pierwszy z nich ma mniejszą bądź równą wartość od drugiego, lub pustą listę w przeciwnym przypadku.</p>

- ->= pobiera dwa parametry typu numerycznego i zwraca 1 w przypadku, gdy pierwszy z nich ma większą bądź równą wartość od drugiego, lub pustą listę w przeciwnym przypadku.
- null? pobiera jeden parametr dowolnego typu i zwraca 1 w przypadku, gdy jest on pustą listą, lub pustą listę w przeciwnym przypadku.
- null nie pobiera żadnych parametrów, zwraca pustą listę.
- cons pobiera dwa parametry dowolnych typów i zwraca parę składającą się z obu pobranych wartości.
- car pobiera jeden parametr, który musi być parą i zwraca pierwszy jej element.
- cdr pobiera jeden parametr, który musi być parą i zwraca drugi jej element.
- typeof pobiera jeden parametr dowolnego typu i zwraca wartość liczbową identyfikującą jego typ.
- sleep pobiera jeden parametr typu numerycznego i usypia mikroproces na taką ilość milisekund, zwraca ilość milisekund, na które mikroproces został uśpiony.
- print pobiera jeden parametr dowolnego typu i wyświetla jego tekstową reprezentację, zwraca parametr.
- self nie pobiera parametrów, zwraca deskryptor obecnie działającego mikroprocesu.
- send pobiera dwa parametry, z których pierwszy musi być deskryptorem mikroprocesu, wysyła drugi parametr jako wiadomość do mikroprocesu z pierwszego parametru.
- recv pobiera jeden parametr typu numerycznego, sprawdza, czy w kolejce wiadomości mikroprocesu znajduje się wiadomość i ją zwraca; jeśli w kolejce wiadomości mikroprocesu nie znajdują się żadne wiadomości zwraca pustą listę i usypia mikroproces na czas przekazany w parametrze.

Spis funkcji wbudowanych

- not przyjmuje jeden parametr i zwraca jego logiczną negację (1 w przypadku logicznej prawdy i pustą listę w przypadku logicznego fałszu).
- and przyjmuje dwa parametry i zwraca ich logiczną koniunkcję; funkcja ta mogła zostać zaimplementowana dzięki leniwej naturze maszyny wirtualnej ThesisVM.
- or przyjmuje dwa parametry i zwraca ich logiczną alternatywę; funkcja ta mogła zostać zaimplementowana dzięki leniwej naturze maszyny wirtualnej ThesisVM.

Dodatkowo wszystkie prymitywne operatory wymienione w powyższej liście mają swoje odpowiedniki funkcyjne o takiej samej nazwie i semantyce.

C. Spisy rysunków i fragmentów kodu

Spis rysunków

1.1.	Schemat interakcji z Maszyną Wirtualną	7
2.1.	Architektura maszyny wirtualnej ThesisVM	11
2.2.	Schemat potokowega działania kompilatora kodu bajtowego ThesisVM wraz ze przykładami reprezentacji danych poszczególnych faz kompilacji	15
2.3.	Różne modele wykorzystania pamięci maszyn wirtualnych	18
2.4.	Różne modele przetwarzania współbieżnego	19
3.1.	Schemat stanu maszyny wirtualnej	23
3.2.	Schemat reprezentacji obiektów prostych ThesisVM	25
3.3.	Schemat reprezentacji obiektów złożonych ThesisVM	26
4.1.	Model współdzielonej pamięci ThesisVM	31
4.2.	Schemat kaskadowych alokatorów wykorzystanych w ThesisVM	33
4.3.	Schemat rejestrów wymaganych przez implementację alokatora obiektów	33
4.4.	Schemat działania zwalniania pamięci obiektów	35
4.5.	Schemat działania alokacji pamięci nowych obiektów	36
5.1.	Schemat symetrycznego multiprocesora ThesisVM	37
5.2.	Schemat rejestrów wymaganych przez usprawnienia hanmonogramowania SMP.	38
5.3.	Schemat rejestrów wymaganych przez implementację Modelu Aktorowego	39
5 4	Schemat działania przesyłania wiadomości	39

Spis listingów

1.1.	Fragment kodu prezentujący problem występujący w języku Erlang	8
1.2.	Suboptymalne rozwiązanie problemu w języku Erlang	9
2.3.	Gramatyka języka TVMIR	13
2.4.	Fragmenty kodu prezentujące operację lambda-unoszenia	14
2.5.	Ograniczona implementacja konstrukcji 1et	14
3.6.	Przykład kodu bajtowego Three Instruction Machine	22
3.7.	Optymalizacja dodawania liczb całkowitych	26
3.8.	Ogólny algorytm implementacji operacji prymitywnych ThesisVM	29